

Quimioinformática: Notación computacional

Cheminformatics · Chemoinformatics

*"La aplicación de métodos informáticos
para resolver problemas químicos"*



Representación

SMILES, InChI, grafos moleculares



Búsqueda

Similitud, subestructura, SMARTS



Propiedades

Descriptores, fingerprints, QSAR



Modelado

ML, redes neuronales, drug discovery

Representación química · De las tarjetas perforadas al PDB




Tarjetas perforadas (Punched Cards)

Las primeras bases de datos moleculares se almacenaban en tarjetas perforadas físicas — cada tarjeta era una molécula.

El Protein Data Bank (PDB, 1971) nació para archivar estructuras 3D de proteínas en formato digital.

El archivo PDB es texto plano: cada línea ATOM contiene tipo de átomo, coordenadas XYZ y cadena.



Wiswesser Line Notation (WLN) · La notación que precedió al SMILES

¿Qué es WLN?

Sistema de notación lineal para moléculas orgánicas propuesto por William J. Wiswesser en 1954.

Fue el estándar de facto para bases de datos químicas durante 30 años (1950–1980).




Usa un alfabeto de símbolos donde cada letra representa un fragmento estructural:

- Q = grupo OH (fenol)
- Z = grupo NH₂
- V = grupo C=O (carbonilo)
- R = anillo bencénico
- L = inicio de anillo no aromático

Ejemplo — Ácido benzoico:

SMILES: OC(=O)c1ccccc1

WLN: QVR

Molecular Structure	Line Notation	Value
	<i>IUPAC Name</i>	methane
	<i>WLN</i>	1H
	<i>SMILES</i>	C
	<i>InChI</i>	InChI=1S/CH4/h1H4
	<i>IUPAC Name</i>	chlorobenzene
	<i>WLN</i>	GR
	<i>SMILES</i>	c1ccccc1Cl
	<i>InChI</i>	InChI=1S/C6H5Cl/c7-6-4-2-1-3-5-6/h1-5H
	<i>IUPAC Name</i>	2-Amino-3-ethylvaleric acid
	<i>WLN</i>	QVYZY2&2
	<i>SMILES</i>	OC(=O)C(C(CCC)CC)N
	<i>InChI</i>	InChI=1S/C7H15NO2/c1-3-5(4-2)6(8)7(9)10/h5-6H,3-4,8H2,1-2H3,(H,9,10)
	<i>IUPAC Name</i>	2-Chloro-2',3,5'-trinitrobiphenyl
	<i>WLN</i>	WNR DNW BR BG CNW
	<i>SMILES</i>	c1ccc(N(=O)=O)c(Cl)c1c(N(=O)=O)ccc(N(=O)=O)c1
	<i>InChI</i>	InChI=1S/C12H6ClN3O6/c13-12-8(2-1-3-11(12)16(21)22)9-6-7(14(17)18)4-5-10(9)15(19)20/h1-6H
	<i>IUPAC Name</i>	5'-[1-(Fluoromethyl)-1H-indol-3-yl]-4',7'-diazaspiro[2,4-cyclopentadiene-1,2'-indene]
	<i>WLN</i>	T56 CX FN INJ C-& AL5XJ& G- DT56 BNJ B1F
	<i>SMILES</i>	C1(=C2)C(=CC2(C=C2)C=C2)N=C(C=N1)C1=CN(C(=CC=C2)C1=C2)CF
	<i>InChI</i>	InChI=1S/C20H14FN3/c21-13-24-12-15(14-5-1-2-6-19(14)24)18-11-22-16-9-20(7-3-4-8-20)10-17(16)23-18/h1-12H,13H2

Notación ideal:

- ✓ Única (canónica)
- ✓ Generada/leída por computadoras
- ✓ Legible por humanos
- ✓ Completa (cubre toda la química orgánica)

SMILES · Simplified Molecular Input Line Entry System

Propuesto por David Weininger (1988). Representa moléculas como cadenas de texto legibles por humanos y computadoras.

Regla 1 · Átomos y cargas

Los elementos se escriben con su símbolo.
Hidrógenos implícitos. Cargas con + / -.

Carboxilato: [O-]C(=O)...

Regla 2 · Enlaces

Simple: implícito · Doble: = · Triple: #

Eteno: C=C | Cianuro: [C-]#[N+]

Regla 3 · Ramificaciones

Las ramas van entre paréntesis ().
El átomo antes del (es el punto de unión.

Propan-2-ol: CC(O)C

Regla 5 · Aromaticidad


Átomos aromáticos en minúscula.
El anillo es aromático si todos sus átomos lo son.

Benceno: c1ccccc1

Regla 4 · Ciclos

Los ciclos se cierran con números.
El mismo número indica el enlace de cierre.

Ciclohexano: C1CCCCC1



N1CCN(CC1)C(C(F)=C2)=CC(=C2C4=O)N(C3CC3)C=C4C(=O)O

SMILES Canónico · Algoritmo Morgan / CANGEN

El mismo SMILES se puede escribir de múltiples formas para la misma molécula. El SMILES canónico garantiza una representación única.

El problema: misma molécula, diferente string

Etanol – todos son válidos:

CCO

OCC

C(O)C

C(C)O

→ Sin canonicalización, no podemos buscar ni comparar.

CANGEN (Weininger, 1989)

Algoritmo de canonicalización basado en Morgan:

1. Asignar número atómico inicial a cada átomo
2. Propagar invariantes por vecindad (iterativo)
3. Numerar átomos en orden único
4. Generar el SMILES en ese orden

RDKit usa CANGEN internamente → `Chem.MolToSmiles(mol)` produce siempre el mismo SMILES para la misma molécula.

¿Para qué sirve el SMILES canónico?

Búsqueda exacta

Encontrar una molécula en una base de datos grande

Deduplicación

Eliminar duplicados al curar datos de ChEMBL

Comparación

Verificar que dos SMILES representan la misma molécula

Features de ML

Input consistente para modelos QSAR y GNNs

InChI · IUPAC International Chemical Identifier

Estándar de IUPAC (2005). Identificador único, jerárquico y universal para moléculas químicas.


c/InChI=1S Prefijo fijo Versión del estándar. Siempre igual.
/

C₈H₁₀N₄O₂/ **Fórmula molecular** Átomos en orden: C, H, luego alfabético.
(capa /f) **(capa /f)** Numeración estricta según la fórmula.

c..../ **Conectividad (capa** Qué átomo está unido a cuál.
/c) **/c)** Corresponde a la topología del SMILES,
sin geometría ni carga.

h..../ **Hidrógenos (capa** Posición de los H móviles y fijos.
/h) **/h)** Separa H transferibles de los fijos.

InChIKey=. **InChIKey (hash)** Hash SHA-256 de 27 caracteres.
.. .. Ideal para búsquedas en bases de datos.



InChI=1S/C15H10Cl2N2O2/c16-8-5-6-12-10(7-8)13(19-15(21)14(20)18-12)9-3-1-2-4-11(9)17/h1-7,15,21H,(H,18,20)

- InChI=1S
- C15H10Cl2N2O2
- 16-8-5-6-12-10(7-8)13(19-15(21)14(20)18-12)9-3-1-2-4-11(9)17
- h1-7,15,21H,(H,18,20)

SMARTS · SMILES Arbitrary Target Specification

Extensión de SMILES para definir patrones de subestructura. Se usa para buscar fragmentos en bases de datos moleculares.

Sintaxis primitiva

<chem>[#6]</chem>	Cualquier carbono (atómico nº 6)
<chem>[c]</chem>	Carbono aromático
<chem>[C]</chem>	Carbono alifático
<chem>[OH]</chem>	Oxígeno con H explícito
<chem>[+]</chem>	Átomo con carga positiva
<chem>[r5]</chem>	Átomo en anillo de 5 miembros
<chem>[!N]</chem>	Cualquier átomo EXCEPTO N
<chem>~</chem>	Cualquier tipo de enlace
<chem>@</chem>	Centro estereogénico (R o S)

Operadores booleanos

& (AND alto)

<chem>[C&H3]</chem>	C con exactamente 3 H
-------------------------	-----------------------

, (OR)

<chem>[N,O]</chem>	N ó O
--------------------	-------

; (AND bajo)

<chem>[#6;r6]</chem>	C alifático en anillo 6
----------------------	-------------------------

! (NOT)

<chem>[!#6]</chem>	Cualquier átomo no-C
--------------------	----------------------

~ (cualquier)

<chem>C~C</chem>	C unido a C por cualquier enlace
------------------	----------------------------------

Ejemplos reales

[CX3](=O)[OX2H1]

Ácido carboxílico

[NX3;H2,H1;!\$(NC=O)]

Amina primaria/secundaria (no amida)

c1ccccc1

Anillo bencénico

[#6]-[#7]=[#8]

Fragmento C-N=O (nitrosocompuesto)

[OH]-[#6]=[O]

Función ácido OH adyacente a carbonilo

PAINS y BRENKs · Filtros de calidad química basados en SMARTS

Subestructuras problemáticas definidas como patrones SMARTS que identifican compuestos interferentes o no-drug-like.

⚠ PAINS · Ejemplos de SMARTS reales

Catecol (quelante) [OH]c1ccccc1[OH]

Forma complejos con metales del ensayo

Enona (reactivo Michael) O=CC=C

Alquilación inespecífica de nucleófilos

Rhodanina O=C1CSC(=S)N1

Scaffold PAINS clásico — agregación

Quinona O=C1C=CC(=O)C=C1

Redox cycling — genera ROS artefactuales

Aldehído α,β -insaturado O=C/C=C/

Reactividad covalente inespecífica

Hidrazida NNC=O

Reactivo con grupos carbonilo proteicos

● BRENKs · ¿Qué son?

Filtros de Brenk et al. (J. Chem. Inf. Model. 2008). 105 subestructuras SMARTS que identifican grupos funcionales problemáticos para drug discovery:

- Toxicidad potencial (mutagénicos, reactivos)
- Inestabilidad química (se degradan in vivo)
 - Propiedades ADME deficientes
 - Artefactos de síntesis indeseables

⚡ BRENKs · SMARTS representativos

Epóxido	<chem>[OX2r3]1[#6r3][#6r3]1</chem>	Alquilante — genotóxico
Nitro aromático	<chem>[\$([NX3](=O)=O)]c</chem>	Mutagénico potencial
Azida	<chem>[N-]=[N+]=[N-]</chem>	Inestable — explosivo
Aldehído	<chem>[CX3H1](=O)</chem>	Reactivo — tóxico
Ácido bórico	<chem>[B]([OH])[OH]</chem>	Inestabilidad hidrolítica

Fingerprints Moleculares · Moléculas como vectores de bits

Un fingerprint convierte una molécula en un vector binario (o de conteo). Permite comparar millones de moléculas con aritmética simple.

¿Qué es un fingerprint?


Molécula → función hash → vector de 1024 o 2048 bits

[0, 1, 0, 0, 1, 1, 0, 1, 0, 0, 1, ...]

Path-based (RDKit FP)

Codifica todos los caminos de longitud hasta k átomos en la molécula. Muy usado como baseline.


`Chem.RDKitFingerprint(mol)`



Circular (Morgan / ECFP)

Entorno circular de radio r alrededor de cada átomo. Estado del arte en QSAR y búsqueda de similitud.


`AllChem.GetMorganFingerprintAsBitVect(mol, r)`



Claves estructurales (MACCS Keys)


166 bits predefinidos — cada bit corresponde a una pregunta sí/no sobre un fragmento específico.

`MACCSkeys.GenMACCSKeys(mol)`



Farmacofórico (ERG, CATS)

Abstrae la molécula a puntos farmacofóricos: donadores, aceptores, hidrofóbicos, cargas. Independiente de la estructura exacta.



Morgan Fingerprint (ECFP) · Radio, Hash y Bits

El algoritmo de Morgan (1965) fue diseñado para canonicalizar numeraciones. Weininger lo adaptó (1988) para generar fingerprints — hoy son el estándar en drug discovery.

↻ Concepto de radio

El radio define cuántos enlaces de vecindad se consideran alrededor de cada átomo central:

- Radio 0 → solo el átomo
- Radio 1 → átomo + vecinos inmediatos
- Radio 2 → ECFP4 (el más usado)
- Radio 3 → ECFP6 (más detalle)

Nomenclatura ECFP:

- ECFP4 = Extended Connectivity FP
radio 2, diámetro 4
- ECFP6 = radio 3, diámetro 6


Mayor radio = más información estructural, pero más sparse.

⚡ Colisiones de hash

Dos entornos distintos pueden caer en el mismo bit: colisión.

Alternativa sin folding:

GetMorganFingerprint(mol,r) → {hash: count} (exacto) / GetMorganFingerprintAsBitVect → binario (posibles colisiones)



Métricas de Similitud · Comparar vectores de bits

Una métrica de similitud transforma dos fingerprints en un número entre 0 y 1. Permite buscar análogos y construir vecindades químicas.

¿Qué mide una métrica de similitud?

Dado FP_A y FP_B: $\text{similitud}(A,B) \in [0, 1] \rightarrow 0 = \text{completamente distintos} \cdot 1 = \text{idénticos}$

⚠ ¿Para qué NO sirven?


- ✗ No predicen actividad biológica directamente Similitud estructural $\neq$ similitud de actividad (problema del 'activity cliff')
- ✗ No son transitivas: $\text{sim}(A,B) \approx 1$ y $\text{sim}(B,C) \approx 1$ no implica $\text{sim}(A,C) \approx 1$
- ✗ Dependen del tipo de fingerprint: Tanimoto(ECFP4) $\neq$ Tanimoto(MACCS)

✓ Filtros por similitud — usos reales

- 🔍 Búsqueda de análogos en ChEMBL
- 🧹 Deduplicación de datasets: Eliminar moléculas casi idénticas
- 🔗 Clustering estructural (scaffold hopping): Agrupar por familia química
- 📊 Aplicabilidad de modelos QSAR ¿La molécula nueva está en el dominio?

Jaccard Similarity

COMPUTE THE SIMILARITY BETWEEN TWO OBJECTS



Métricas de Similitud · Tanimoto · Euclídea · Coseno

Ejemplo: $FP_A = [1,1,0,1,0]$ · $FP_B = [1,0,0,1,1]$ → $a=3$ bits, $b=3$ bits, $c=2$ bits en común

Tanimoto (Jaccard)

$$T(A,B) = c / (a + b - c)$$

c = bits encendidos en A Y B

a = bits encendidos en A

b = bits encendidos en B

$$\rightarrow T = 2 / (3+3-2) = 2/4 = 0.50$$

Propiedades:

Rango: $[0, 1]$

Invariante a la longitud del FP

Penaliza bits extras ($a+b-c$)

No es distancia métrica estricta

Umbral práctico:

$T \geq 0.85 \rightarrow$ muy similares

$T \geq 0.40 \rightarrow$ relación estructural

★ Estándar de facto — Drug Discovery

Distancia Euclídea

$$d = \sqrt{\sum_i (a_i - b_i)^2}$$

Diferencia posición a posición,
elevada al cuadrado y sumada.

$$\rightarrow d = \sqrt{(0+1+0+0+1)} = \sqrt{2} \approx 1.41$$

Convertir a similitud:

$$\text{sim} = 1 / (1 + d) \approx 0.41$$

Problemas para fingerprints:

Sensible a la longitud del vector

Moléculas grandes → FP más densos

→ distancias mayores por tamaño,
no por disimilitud real

Útil con descriptores continuos
(LogP, MW...) — normalizar antes.

Rango d : $[0, \sqrt{n_bits}]$

NB-03 · Quimioinformática · UNAL 2026

Similitud del Coseno

$$\cos = A \cdot B / (|A| \cdot |B|)$$

Producto punto dividido entre
el producto de las normas.

$$\rightarrow A \cdot B = 1+0+0+1+0 = 2$$

$$|A| = \sqrt{3} \approx 1.73$$

$$|B| = \sqrt{3} \approx 1.73$$

$$\cos = 2 / (1.73 \cdot 1.73) = 0.67$$

Propiedades:

Rango: $[0, 1]$ para bits ≥ 0

Ignora la 'densidad' del FP

Solo mide la orientación
del vector en el espacio

Útil para FP de conteo (Morgan
sin folding) y ProLIF.

$1 - \text{distance.cosine}(a, b)$

Archivos 3D · Coordenadas, conectividad y propiedades

Los formatos 2D (SMILES, InChI) describen la topología molecular. Los archivos 3D añaden las coordenadas espaciales reales de cada átomo.

¿Qué añade la tercera dimensión?

Coordenadas XYZ

Posición de cada átomo en el espacio (Å)

Conectividad

Qué átomo se une a cuál y con qué orden de enlace

Cargas

Carga formal y carga parcial de cada átomo

Estereoquímica

Configuración R/S, geometría E/Z, quiralidad axial

PDB

Protein Data Bank

- Creado en 1971 para estructuras proteicas
- Columnas de ancho fijo (formato heredado)
- Registros ATOM, HETATM, CONECT
- Separa proteína, ligandos y agua
- Limitado a 99.999 átomos por archivo
- Usado en docking y simulaciones

Usos:

Docking molecular

Visualizadores (PyMOL, NGLview)

Cristallografía, cryo-EM

SDF

Structure Data File

- Formato estándar para moléculas pequeñas
- Varios registros por archivo (multi-mol)
- Incluye tabla de conexiones (V2000/V3000)
- Propiedades adicionales como clave-valor
- Compatible con RDKit, OpenBabel, MOE
- Sin límite de átomos en V3000

Usos:

Bases de datos (ChEMBL, PubChem)

Docking de ligandos

Bibliotecas de cribado virtual

MOL

MDL Molfile (un solo mol)

- Subconjunto del SDF (una sola molécula)
- Tabla de átomos + tabla de enlaces
- Especifica coordenadas X, Y, Z
- Incluye cargas y multiplicidad
- Versiones V2000 (clásica) y V3000
- Base de SDF, SD y otros formatos MDL

Usos:

Estructura individual

Edición en MarvinSketch, Avogadro

Intercambio entre software

XYZ

XMOL / XYZ format

- El más simple: n_átomos + coordenadas
- Sin información de enlace
- Sin cargas ni propiedades
- Usado en química computacional / DFT
- Fácil de generar con cualquier lenguaje

Usos:

Cálculos DFT / ab initio

Dinámica molecular

Visualizadores científicos (VESTA, Avogadro)

Archivo PDB · Anatomía y columnas detalladas

Formato de texto plano con columnas de ancho fijo — heredado de las tarjetas perforadas. Cada línea comienza con un registro de 6 caracteres.

Tipos de registro principales								
HEADER	TITLE	REMARK	SEQRES	HELIX / SHEET	ATOM	HETATM	CONNECT	END
Clasificación y fecha de deposición	Título descriptivo de la estructura	Notas: resolución, método, R-factor	Secuencia de aminoácidos de cada cadena	Estructura secundaria (hélices y láminas)	Átomos de la proteína / ácido nucleico	Ligandos, agua, iones, cofactores	Conectividad explícita del ligando	Marca el fin del archivo

Ejemplo — línea ATOM / HETATM:												
ATOM	1	CA	ALA	A	7	11.104	6.134	-6.504	1.00	49.84		C
ATOM	2	O	ALA	A	7	12.036	5.987	-4.236	1.00	98.78		O

1–6	7–11	13–16	17	18–20	22	23–26	31–38	39–46	47–54	55–60	61–66	77–78
Registro	Nº átomo	Nombre	Alt. loc.	Residuo	Cadena	Nº resid.	X (Å)	Y (Å)	Z (Å)	Ocup.	B-factor	Elemento
ATOM o HETATM	Número serial del átomo	Nombre del átomo (CA, N, O...)	Ubicación alternativa (A, B...)	Nombre del aminoácido o ligando	ID de cadena (A, B, C...)	Número del residuo	Coordenada X en Ångströms	Coordenada Y en Ångströms	Coordenada Z en Ångströms	Ocupancia (0.0–1.0)	Factor de temperatura (Å²)	Símbolo del elemento (C, N, O...)

 **Coordenadas en Ångströms (Å) — 1 Å = 0.1 nm**

Los enlaces C–C típicos miden 1.54 Å · C=O carbonilo: 1.22 Å · Radio van der Waals del C: 1.7 Å

 **B-factor (factor de temperatura / factor B)**

Mide la movilidad/incertidumbre de cada átomo. B alto → átomo muy móvil o mal resuelto. Importante en docking.

SDF y MOL · Estructura, diferencias y ejemplos

Ambos son formatos MDL (Molecular Design Limited, 1985). El MOL es la unidad básica; el SDF es una colección de MOLs con propiedades.

Característica	MOL (Molfile)	SDF (Structure-Data File)
Moléculas por archivo	1 (una sola)	N (múltiples, separadas por \$\$\$\$)
Propiedades adicionales	No	Sí — bloques clave-valor arbitrarios
Extensión	.mol	.sdf o .sd
Versiones	V2000 (clásica) / V3000 (moderna)	V2000 y V3000 (mismo molblock)
Coordenadas	Obligatorias (2D o 3D)	Obligatorias en el molblock
Enlace en bases de datos	Descarga individual	Descarga en batch (ChEMBL, PubChem)
Compatibilidad RDKit	Chem.MolFromMolFile()	Chem.SDMolSupplier()

SDF y MOL · Estructura, diferencias y ejemplos

Ambos son formatos MDL (Molecular Design Limited, 1985). El MOL es la unidad básica; el SDF es una colección de MOLs con propiedades.


Estructura de un archivo .mol (aspirina, V2000)

```
Aspirina
RDKit          3D

 9  9  0  0  0  0  0  0  0  0999 V2000
 1.1925 -0.3985  0.0000 C  0  0  0  ...
 2.5648 -0.0528  0.0000 C  0  0  0  ...
 0.0000  0.3760  0.0000 O  0  0  0  ...
 1  2  2  0      ← enlace doble (C=C)
 1  3  1  0      ← enlace simple (C-O)
M  END
```

Estructura de un archivo .sdf (multi-molécula)

```
Aspirina
RDKit          3D      ← línea de comentario
 9  9  0  0  ... V2000
...átomos y enlaces...
M  END
> <pIC50>              ← bloque de propiedad
7.23
> <molecule_chembl_id>
CHEMBL25
$$$$                  ← separador entre moléculas
Ibuprofeno
...siguiente molécula...
```



SDF / MOL · Tabla de conexiones, tipos de enlace y RDKit

El corazón del formato MDL es la tabla de conexiones (connection table). Define explícitamente cada átomo y cada enlace de la molécula.



Atom block — una línea por átomo

x (Å)	y (Å)	z (Å)	Elem.	massDif f	Carga
1.193	-0.399	0.000	C	0	0
2.564	-0.053	0.000	C	0	0
0.000	0.376	0.000	O	0	5

Carga: 0=neutral, 1=+3, 2=+2, 3=+1, 4=radical, 5=-1, 6=-2, 7=-3



Bond block — una línea por enlace


Átomo 1	Átomo 2	Tipo	Estéreo
1	2	2 (doble)	0
1	3	1 (simple)	0
2	4	1 (simple)	1 (Up)
3	5	1 (simple)	6 (Down)

Tipo de enlace: 1=simple 2=doble 3=triple 4=aromático · 8=cualquiera

MOL I
bond table

1	2	1	0
2	3	2	0
3	4	1	0
4	5	2	0
5	6	1	0
6	1	2	0
5	7	1	0
7	8	1	0
7	9	2	0

Kekulé A




I

MOL IV
bond table

1	2	2	0
2	3	1	0
3	4	2	0
4	5	1	0
5	6	2	0
6	1	1	0
5	7	1	0
7	8	1	0
7	9	2	0

Kekulé B




IV

MOL V
bond table

1	2	4	0
2	3	4	0
3	4	4	0
4	5	4	0
5	6	4	0
6	1	4	0
5	7	1	0
7	8	1	0
7	9	2	0

Aromatic



V

Same set of atom-to-atom connections